



# NEURONSKE MREŽE

Milan M.Milosavljević

# Biološka inspiracija





Van Gog



# Šagal



# Diskriminatorna svojstva bioloških neuronskih mreža


- Golub je u stanju da diskriminiše sa tačnošću od 95% između Šagala i Van Goga, na skupu vidjenih primera
- Ova tačnost je još uvek visoka, oko 85%, na skupu novih nevidjenih primera
- Očigledno da golub ne vrši jednostavno memorisanje, već izdvaja i prepoznaje oblike, koji mu omogućuju dobru generalizaciju

# Zašto učimo od našeg neuronskog sistema?

- Naš mozak je još uvek superioran u odnosu na savremene računare u mnogim aspektima
- Posедуje svojstven način procesiranja:
  - Paralelno distributivno procesiranje informacija
  - Adaptivnost i mogućnost učenja novog znanja
  - Univerzalna računarska arhitektura: ista struktura izvršava mnogo različitih funkcija



# Kako izgleda biološki neuronski sistem




© Digital Studio, Paris - France. All rights reserved.



DIGITAL STUDIO SA

CG image of the vertical organization of neurons in the primary visual cortex (V1).  
Smooth stellate and spiny stellate cells relay visual information coming out from the retina to pyramidal cells,  
themselves doing a first basic computation of visual motion perception.  
version of July 2000


# Funkcionisanje jednog neurona





# Neuron kao osnovna računarska jedinica

- Neuron provodi kada je aktivacioni potencijal veći od praga
- Neuron se može naći u dva stanja:  
provodjenje (on) i neprovodjenje (off)



# Neuron kao osnovna računarska jedinica

- Broj neurona:  $\sim 10^{10}$
- Broj sinapsi po neuronu:  $10^4$  to  $10^5$
- Vreme promene stanja neurona  
(switching time) :  $\sim 0.001$  sec
- Vreme prepoznavanje scene:  $\sim 0.1$  sec

# Definicija neuronskih mreža

- Neuronske mreže simuliraju način rada ljudskog mozga pri obavljanju datog zadatka ili neke funkcije. Neuronska mreža je masovno paralelizovan distribuirani procesor sa prirodnom sposobnošću memorisanja iskustvenog znanja i obezbeđivanja njegovog korišćenja. Veštačke neuronske mreže podsećaju na ljudski mozak u dva pogleda:
  1. Neuronska mreža zahvata znanje kroz proces obučavanja
  2. Težine medjuneuronskih veza (jačina sinaptičkih veza) služe za memorisanje znanja.

- Procedura kojom se obavlja obučavanje je algoritam obučavanja. Kroz ovu se procesuru se na algoritamski (sistematičan) način menjaju sinaptičke težine u cilju dostizanja željenih performansi mreže.
- Osnovnu računarsku snagu neuronskih mreža čini masivni paralelizam, sposobnost obučavanja i generalizacija.
- Generalizacija predstavlja sposobnost produkovanja zadovoljavajućeg izlaza neuronske mreže i za ulaze koji nisu bili prisutni u toku obučavanja.



# Svojstva neuronskih mreža


- Nelinearnost, koja je u osnovi distribuirana.
- Ulazno-izlazno preslikavanje, koje se restauriše kroz proces obučavanja
- Adaptivnost-sposobnost menjanja jačine sinaptičkih veza.
- Evidencionalni odziv. Neuronska mreža kao izlaz može da produkuje i stepen uverenja o datoj odluci.
- Kontekstualna informacija. Svaki neuron u neuronskoj mreži je pod uticajem globalne aktivnosti ostalih neurona. Stoga je kontekstualna informacija prirodno imanentna ovim strukturama

# Svojstva neuronskih mreža

- Otpornost na otkaz.
- Mogućnost realizacije u VLSI (Very Large Scale Integration) tehnologiji.
- Uniformnost analize i sinteze. Neuron je zajednički element za sve tipove neuronskih mreže. Modularne neuronske mreže se mogu formirati integracijom pojedinih celina-modula. Za rešavanje različitih praktičnih problema koriste se iste teorijske postavke i algoritmi obučavanja.
- Neurobiološke analogije. Neurobiolozi gledaju na neuronske mreže kao istraživački alat za interpretaciju neurobioloških fenomena, i obrnuto, inženjeri gledaju na neurobiologiju kao oblast iz koje mogu da izvlače nove ideje za rešavanje kompleksnijih problema od onih koji se mogu rešiti klasičnim hardversko-softverskim tehnikama.

# Modeli neurona

- Model neurona čine tri bazična elementa:
- Skup sinaptičkih težina . Pozitivne težine odgovaraju ekscitirajućim sinaptičkim vezama, a negativne inhibitornim.
- Sumator (linearni kombajner) – formira težinsku sumu ulaza.
- Aktivaciona funkcija – limitira amplitudu izlaznog signala neurona. Tipično se uzima normalizacija izlaza na interval  $[0,1]$  ili  $[-1,1]$ .

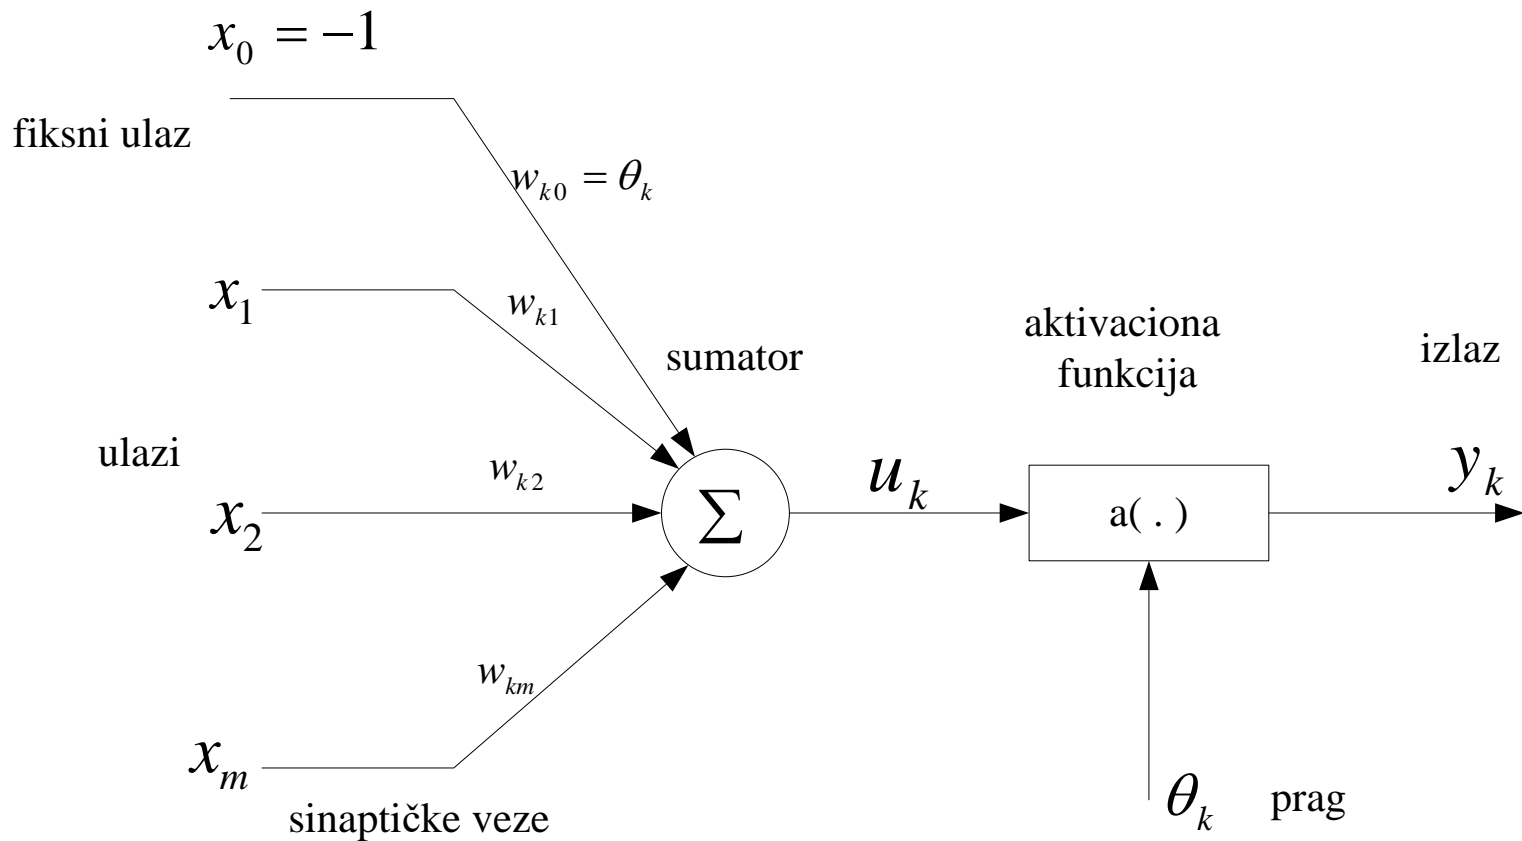




$$u_k = \sum_{j=1}^m w_{kj} x_j$$

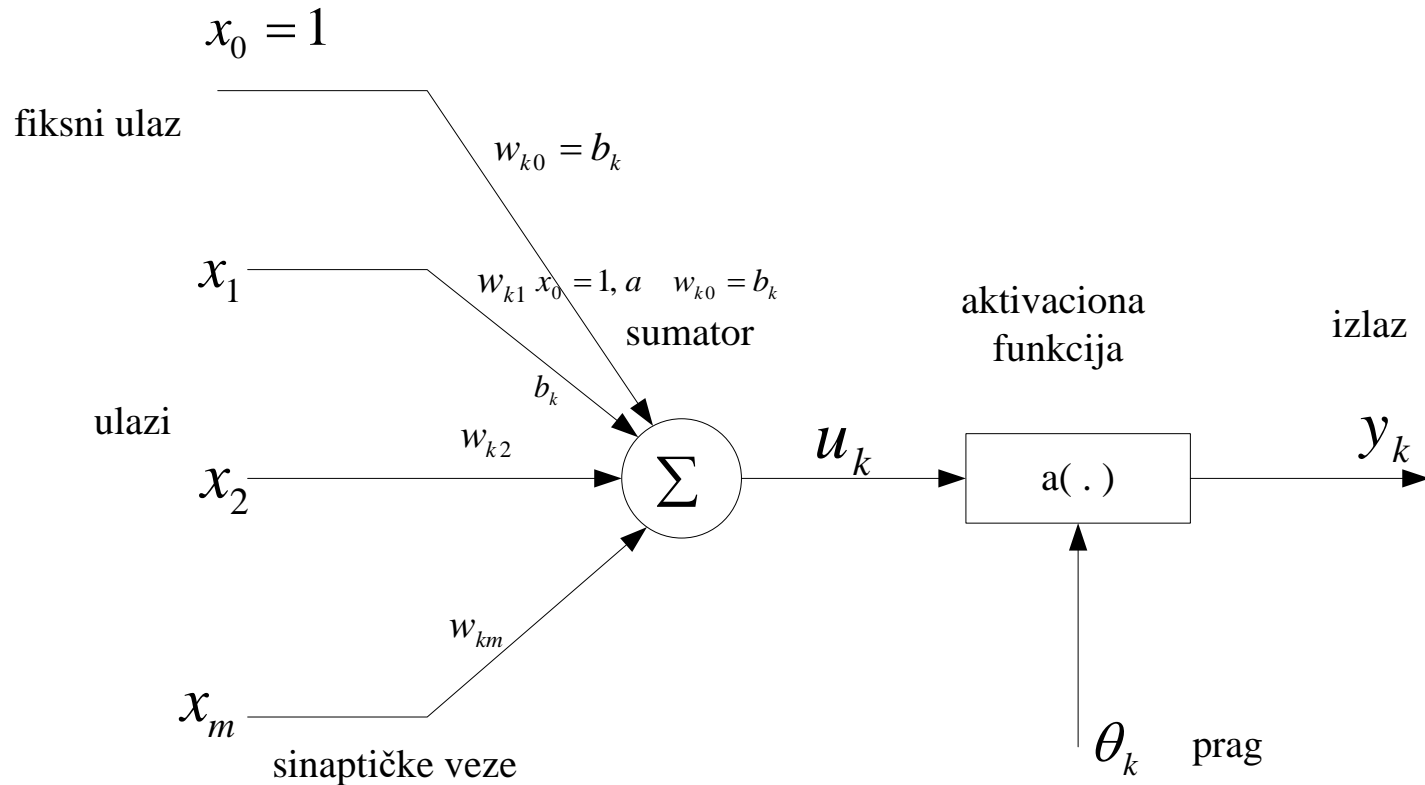
$$y_k = a(u_k - \theta_k)$$

$$v_k = \sum w_{kj} x_j, \quad y_k = a(v_k), \quad x_0 = -1, \quad w_{k0} = \theta_k.$$



Nelinearni model neurona sa proširenim ulazom i prenosom praga u sinaptičku težinu.

Ako stavimo da je  $x_0 = 1$ , a  $w_{k0} = b_k$ , tada se  $b_k$  naziva bias, videti sl.3.3.




Sl.3.3. Nelinearni model neurona sa proširenim ulazom i biasom u obliku sinaptičke težine

# TIPOVI AKTIVACIONIH FUNKCIJA

- Razlikujemo sledeće najčešće tipove aktivacionih funkcija.
- Funkcija praga

$$a(v) = \begin{cases} 1, & v \geq 0 \\ 0, & v < 0 \end{cases}$$




Sl.3.4. Aktivaciona funkcija tipa praga. Neuron sa ovom aktivacionom funkcijom je poznat kao Mek Kalok – Pitasov model neurona (1943)




## U delovima linearna

$$a(v) = \begin{cases} 1, & v \geq 1/2 \\ 1/2 + v, & -1/2 < v < 1/2 \\ 0, & v \leq -1/2 \end{cases}$$




## Sigmoidalna (logistička)

$$a(v) = \frac{1}{1 + \exp(-bv)}$$




Sigmoidalna (logistička) aktivaciona funkcija. Parametar  $b$  je parametar nagiba.

$$a(v) = \begin{cases} 1, & v \geq 0 \\ 0, & v = 0 \\ -1, & v < 0 \end{cases}$$




Bipolarna aktivaciona funkcija tipa znaka ( $\text{sgn}(v)$ )

$$a(v) = \tanh\left(\frac{v}{2}\right) = \frac{1 - \exp(-v)}{1 + \exp(-v)}$$




Bipolarna aktivaciona funkcija tipa tangensa  
hiperboličnog (sigmoidalna aktivaciona funkcija)

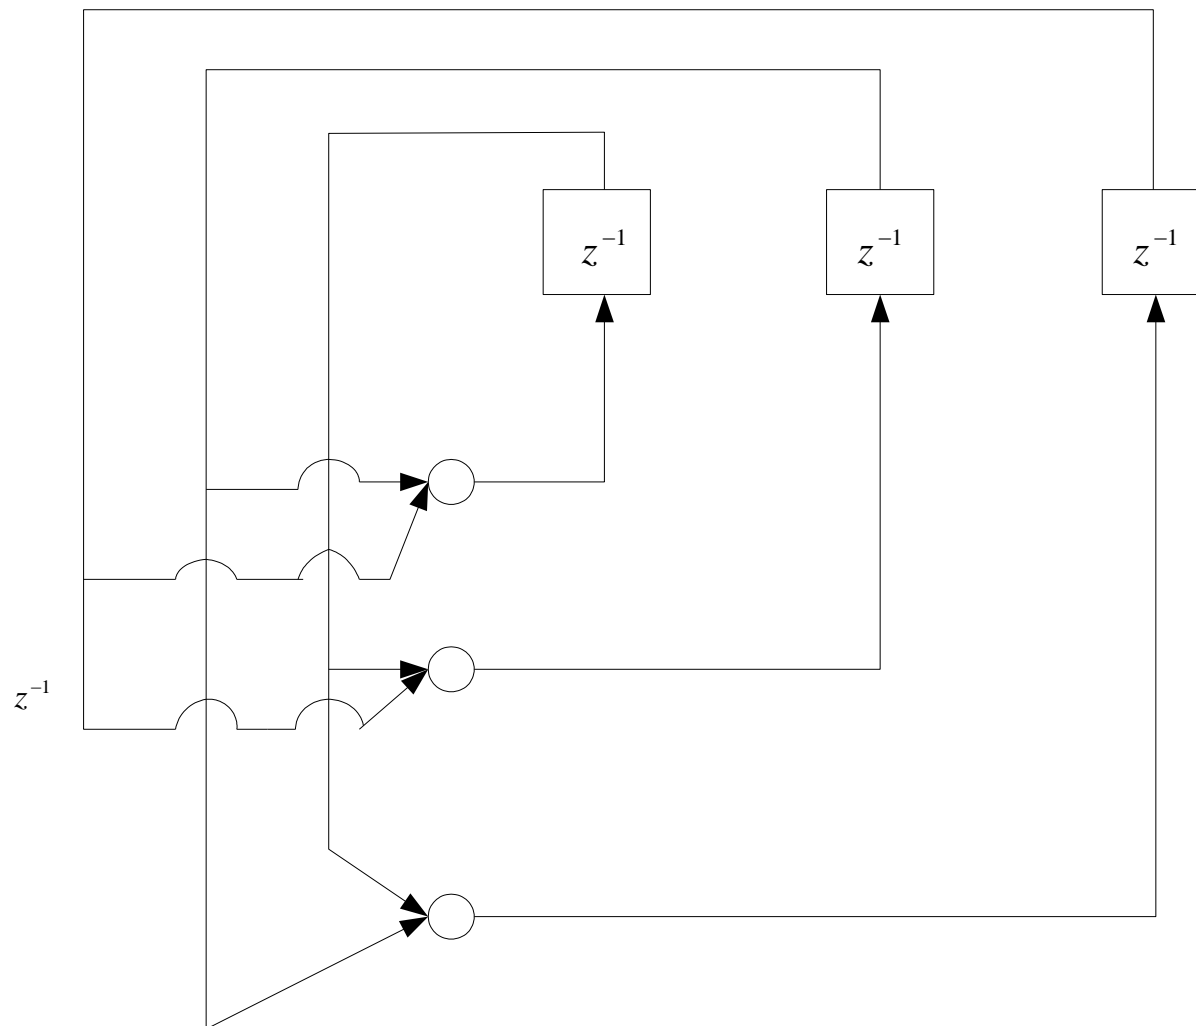


Jednoslojni perceptron sa prostiranjem unapred

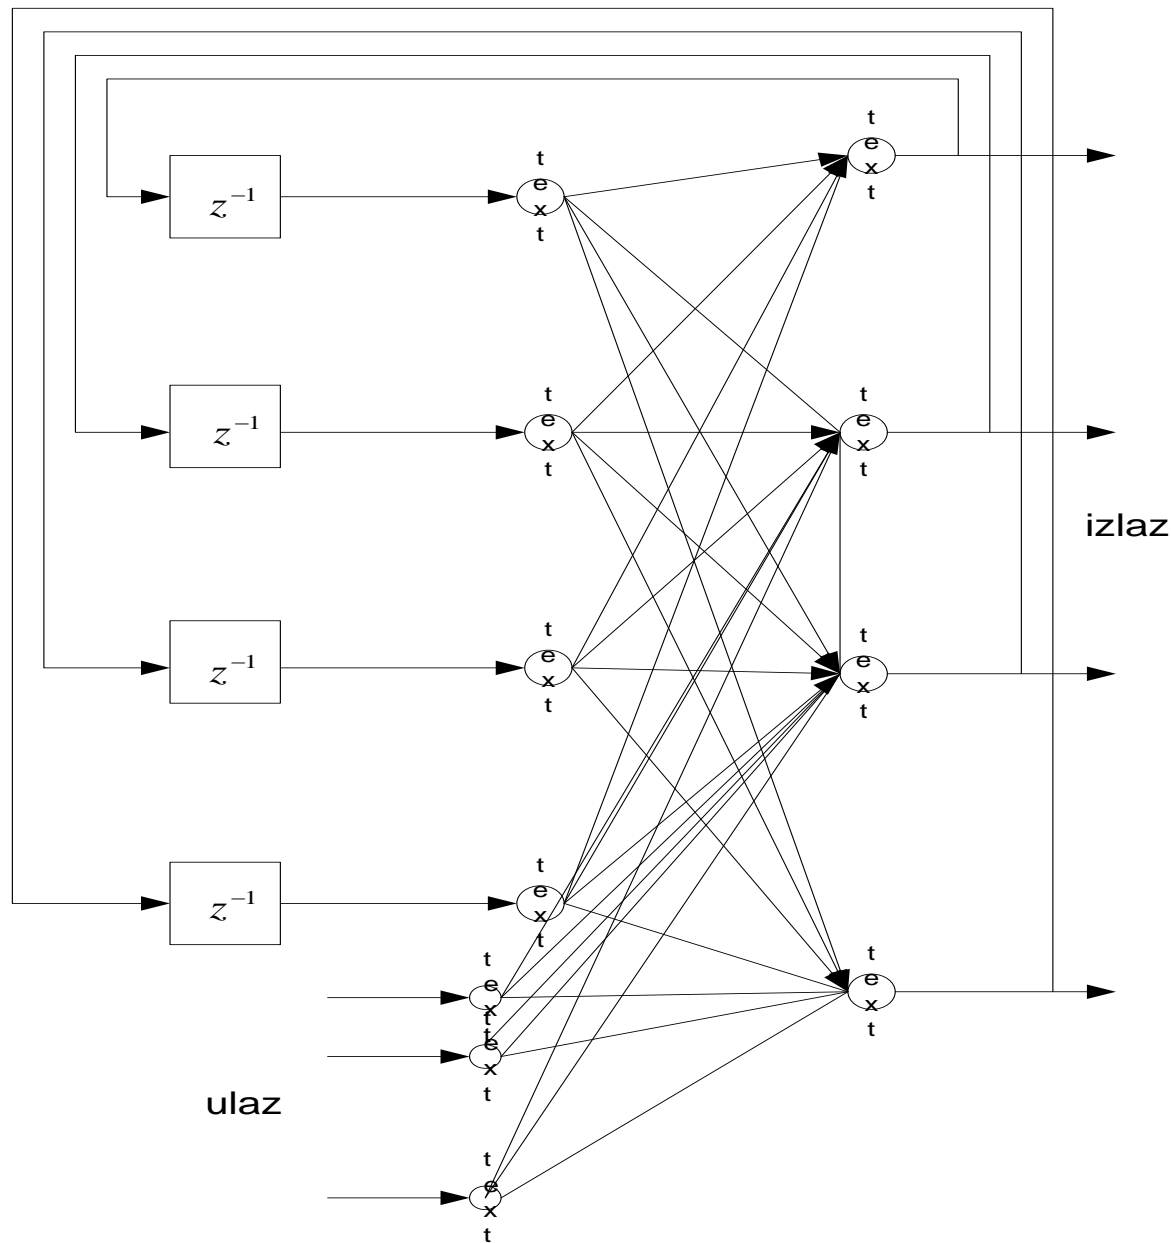




Višeslojna neuronska mreža sa prostiranjem unapred



Rekurentna neuronska mreža bez sopstvenih povratnih sprega i skrivenih slojeva. Operator  $z^{-1}$  ima značenje jediničnog vremenskog kašnjenja



Rekurentna neuronska mreže sa skrivenim slojem

# Prezentacija znanja u neuronskim mrežama

- Znanje o okruženju je generalno dvojako
- Poznata znanja o okruženju, izražena kroz činjenice o tome šta je poznato – apriorno znanje.
- Observacije (merenja) – dobijena od različitih senzora kao odraz stanja okruženja. Na osnovu ovih observacija se kreiraju obučavajući skupovi za obučavanje neuronskih mreža. Svaki primer u njemu se sastoji od parova (ulaz, izlaz).
- Obučavajući skupovi predstavljaju znanje o okruženju od interesa.

- U klasičnom procesiranju, prirodno je prvo kreirati matematički model observacija, izvršiti validaciju ovog modela na realnim podacima
- Neuronske mreže su direktno bazirane na podacima i daju implicitni model okruženja uz istovremeno obavljanje željenog procesiranja.
- Znanje o okruženju u neuronskim mrežama je kodovano kroz konkretne vrednosti slobodnih parametara dobijenih kroz obučavanje.
- Teško je bilo šta konkretno reći o reprezentaciji samog znanja unutar neuronske mreže.



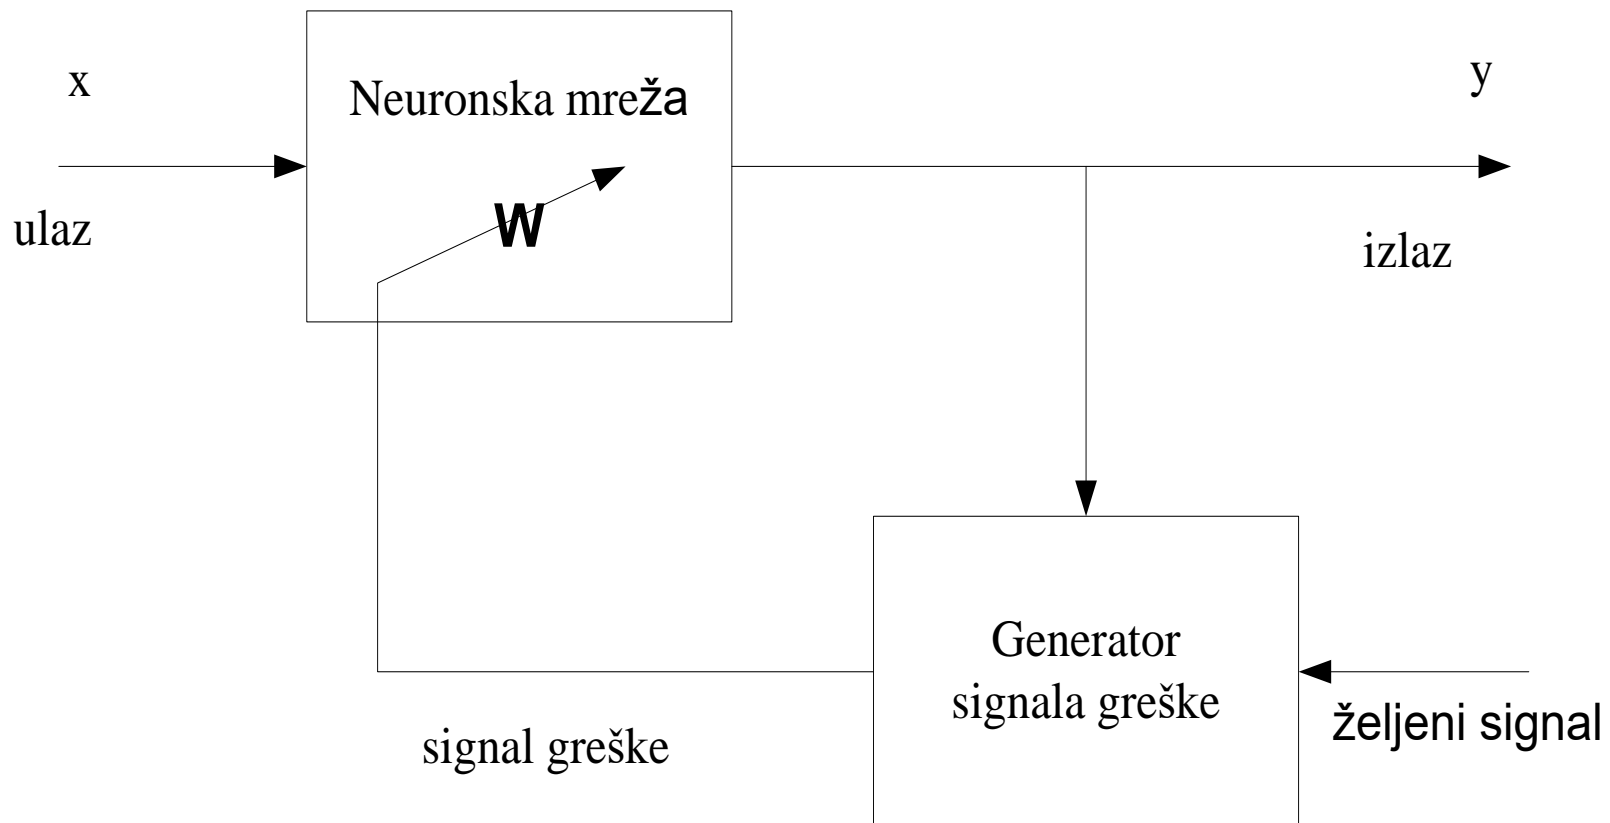
- Postoje četiri pravila o reprezentaciji znanja u neuronskim mrežama, koji su opšte prirode.
- Pravilo 1. Slični ulazi sličnih klasa prouzrokuju sličnu unutrašnju reprezentaciju.
- Pravilo 2. Primeri koji pripadaju različitim klasama treba da budu predstavljeni različitim unutrašnjim reprezentacijama.
- Pravilo 3. Apriorne informacije se ugrađuju direktno u neuronsku mrežu bez procesa obučavanja (specijalizacija strukture). Ovo se postiže ili
  1. restrikcijom arhitekture (lokalne konekcije)
  2. restrikcijom izbora sinaptičkih težina (weight shearing – metoda zajedničkih sinaptičkih težina).

Specijalizacijom strukture se postiže:

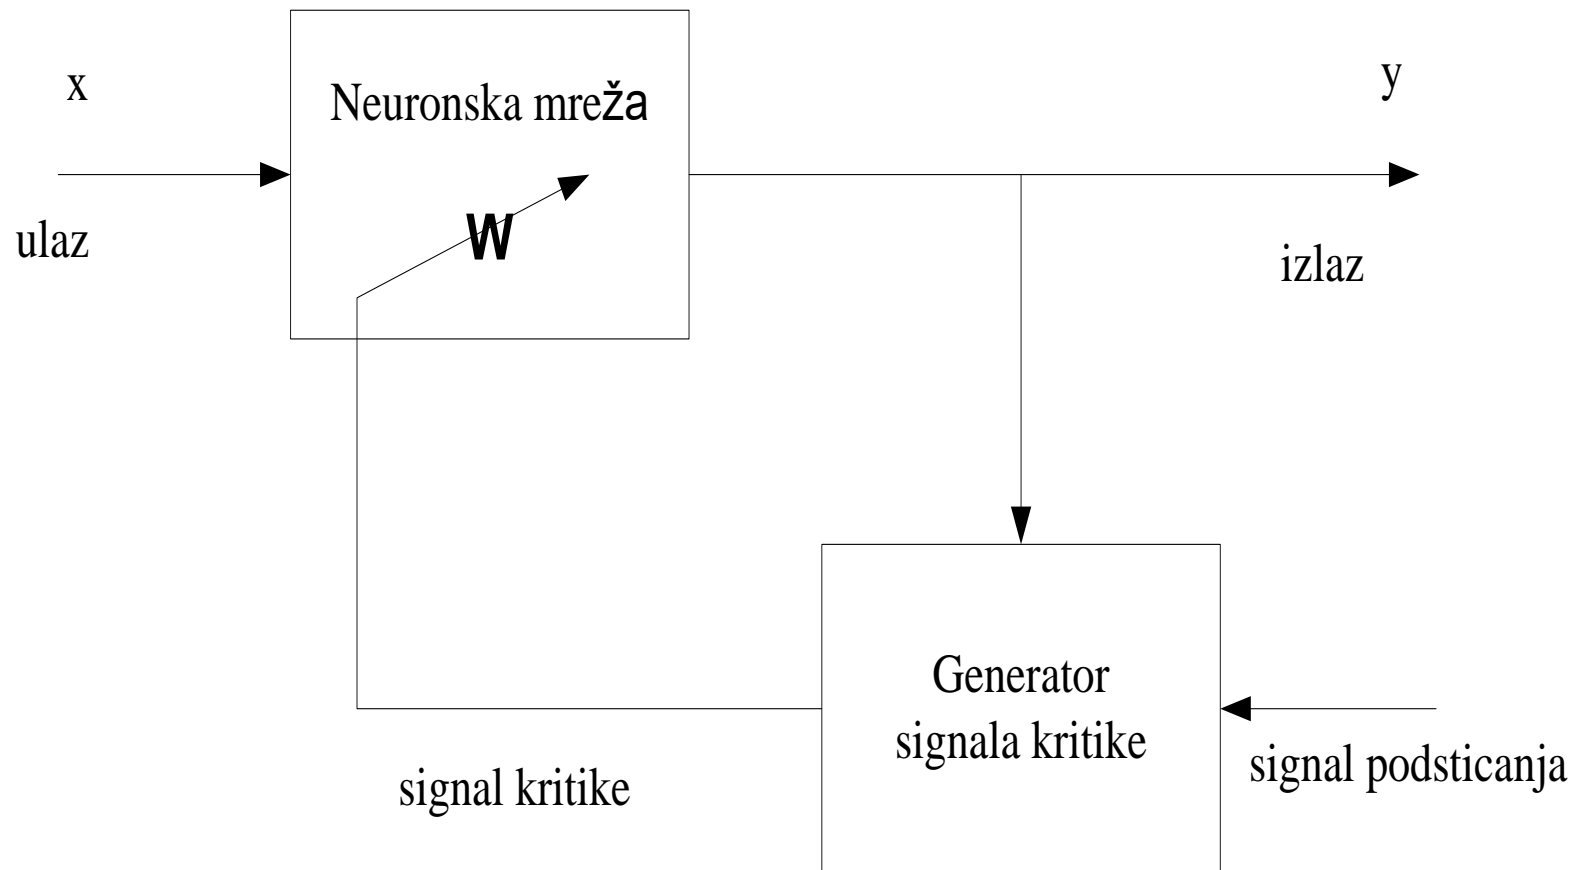
- manji broj slobodnih parametara
- manji potrebni obučavajući skupovi
- brže obučavanje
- bolja generalizacija
- ubrzana je prenos signala kroz restriktovanu neuronsku mrežu
- cena realizacije je manja.

# Obučavanje neuronskih mreža


- Obučavanje je proces adaptiranja slobodnih parametara neuronske mreže, koji se obavlja kroz stimulaciju okruženja u kome se neuronska mreža nalazi. Proces obučavanja je klasifikovan u tri kategorije:
  1. obučavanje sa učiteljem (nadzorom),  
(supervised learning)
  2. obučavanje sa podsticanjem (reinforcement learning)
  3. samoobučavanje (obučavanje bez učitelja),  
(unsupervised learning)



Obučavanje sa učiteljem



Obučavanje sa podsticanjem



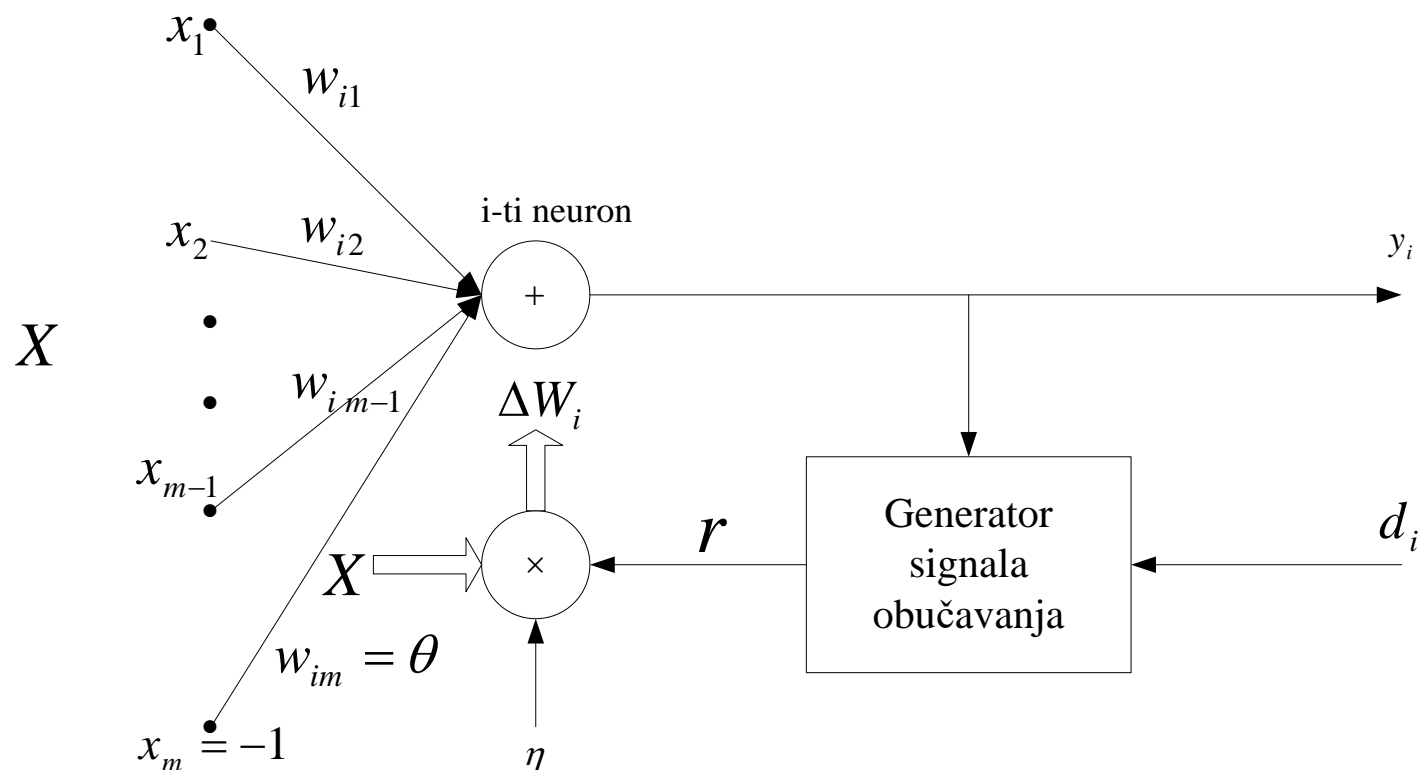
Samoobučavanje

Kod obučavanja sa učiteljem prisutan je obučavajući skup u formi parova  $\{X^{(i)}, d^{(i)}\}$

gde je  $X^{(i)}$  ulaz, a  $d^{(i)}$  željeni izlaz.

Kod obučavanja sa podsticanjem, neuronska mreža dobija rudimentirane informacije o tome kakav izlaz produkuje, najčešće samo u formi jednog bita informacije tipa {dobar, loš}. Analogno obučavanju sa učiteljem, ova forma obučavanja se može tretirati na isti način s tim što umesto učitelja, koji egzaktno ukazuje kakav odziv neuronske mreže treba da bude, u ovom slučaju imamo “kritičara” koji daje grublju ocenu odziva neuronske mreže. Samoobučavanje je karakterisano odsustvom bilo kakve povratne sprege od okruženja.

# OPŠTA FORMA PRAVILA OBUČAVANJA



Opšta šema obučavanja i-tog neurona




# Hebovo učenje

- Hebov princip učenja je jedan od najstarijih i najpoznatijih. Zasniva se na Hebovom postulatu:
- *Kada je akson neurona A dovoljno blizu neurona B, tako da ga može eksitovati, i ako se to ponavlja dovoljno često, dešavaju se takve promene i metabolički procesi u obe ćelije da je efikasnost uticaja neurona A na neuron B povećana.*

$$r = y_i, \quad \Rightarrow \quad \Delta w_i = \eta y_i x.$$


Hebovo učenje je u osnovi samoobučavajuće, budući da nije prisutan signal željenog izlaza. U skalarnoj formi (6.4), ima formu

$$\Delta w_{ij} = \eta y_i x_j, \quad i = 1, 2, \dots, n, \quad j = 1, 2, \dots, m$$



Ilustracija Vidrov-Hofovog pravila obučavanja za jedan koeficijent sinaptičkih težina  $w$ .

# Gradientna metoda

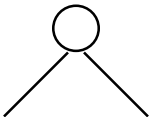
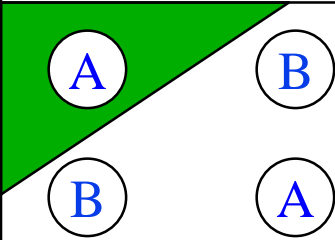
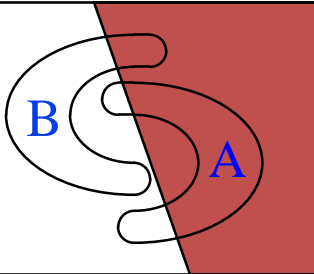
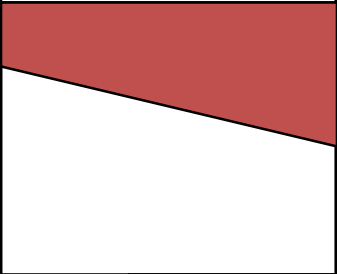
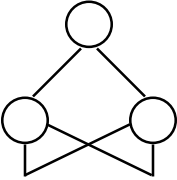
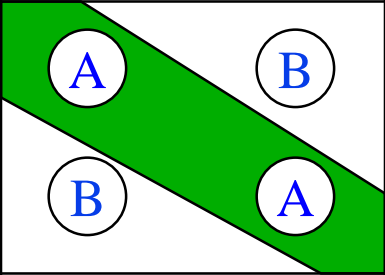
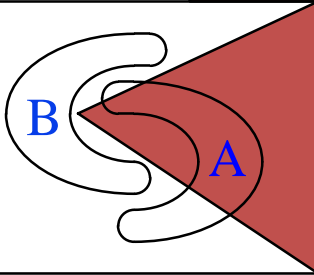
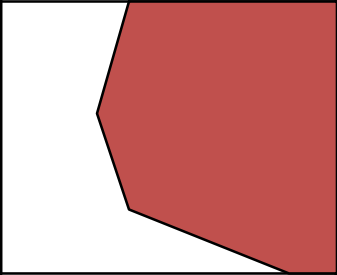
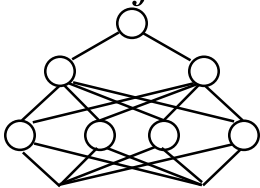


$$E[\vec{w}] = \frac{1}{2} \sum_{d \in D} (t_d - o_d)^2$$

Gradient: 
$$\nabla E[\vec{w}] = \left[ \frac{\partial E}{\partial w_0}, \frac{\partial E}{\partial w_1}, \dots, \frac{\partial E}{\partial w_n} \right]$$

Pravilo obučavanja: 
$$\Delta \vec{w} = -\eta \nabla E[\vec{w}] \quad \Delta w_i = -\eta \frac{\partial E}{\partial w_i}$$

# Različiti linearno nesparabilni problemi

<i>Struktura</i>	<i>Tip regiona odlučivanja</i>	<i>Ekskluzivni OR problem</i>	<i>Klase sa zapetljanim regionima</i>	<i>Najopštiji oblici regiona</i>
<i>Jednoslojna</i> 	<i>Granice sa poluravnima</i>			
<i>Dvoslojna</i> 	<i>Konveksni otvoreni ili zatvoreni regioni</i>			
<i>Troslojna</i> 	<i>Proizvoljni (kompleksnost je limitirana brojem neurona)</i>	